

Picking Robótico Bimanual Guiado por Tendencias de Moda:

Estado del Arte y Propuesta Arquitectónica para el Cierre del Bucle IT-OT en Intralogística Textil

Víctor Martín Parra
Máster Universitario en Robótica y Automatización
Universidad Carlos III de Madrid
Leganés, España
victormpar@gmail.com

Resumen—La logística de la moda rápida (*fast fashion*) opera bajo dos presiones simultáneas: ciclos de tendencia cada vez más cortos, impulsados por las redes sociales, y una demanda creciente de personalización de pedidos por mercado geográfico. El *picking* de prendas en los centros de distribución sigue siendo, en gran medida, una tarea manual, mientras que la inteligencia de mercado generada por los departamentos de marketing rara vez llega, de forma automatizada, hasta la planta de operaciones. Este artículo presenta una revisión del estado del arte en tres campos habitualmente tratados de forma independiente — la manipulación robótica de textiles, la clasificación de prendas mediante visión por computador y los modelos multimodales visión-lenguaje, y la predicción de tendencias de moda mediante inteligencia artificial — y propone una arquitectura de sistema que integra estos tres campos en un único bucle IT-Middleware-OT. La propuesta se articula en cinco modos de operación progresivos, desde el vaciado geométrico de cajas hasta la optimización multiobjetivo que combina demanda geográfica y alineamiento con tendencias sociales, empleando un robot colaborativo bimanual, una taxonomía de prendas de 29 clases diseñada específicamente para picking industrial y un espacio semántico compartido basado en modelos de lenguaje-visión. El documento identifica el vacío de investigación que motiva el futuro Trabajo Fin de Máster, describe la arquitectura propuesta a alto nivel, discute escenarios de aplicación ilustrativos y presenta la planificación de trabajo prevista.

Palabras clave—robótica colaborativa, manipulación de textiles, visión por computador, modelos multimodales, CLIP, picking robótico, integración IT/OT, Industria 4.0, predicción de tendencias de moda, intralogística

I. INTRODUCCIÓN

A. Contexto y motivación

La industria del *fashion retail* gestiona hoy un volumen de referencias y una velocidad de rotación de catálogo sin

precedentes. Grupos de moda multimarca que operan a la escala de Inditex mantienen decenas de miles de referencias activas de forma simultánea en sus centros de distribución, y la vida útil de un estilo concreto — antes medida en meses — se ha reducido a semanas, empujada por la cultura del *outfit del día* y por la viralidad de plataformas como TikTok o Instagram. A esta presión temporal se suma una presión geográfica: el mismo catálogo de artículos debe distribuirse con composiciones de pedido distintas según el mercado de destino, atendiendo a diferencias regulatorias, culturales y comerciales.

En este contexto, el *picking* — la selección y extracción física de prendas para conformar un pedido — continúa siendo, en la mayoría de centros de distribución, una operación manual o semi-automatizada que depende de la habilidad de un operario humano para interpretar órdenes de trabajo y localizar productos. La automatización de esta tarea mediante robótica colaborativa es un objetivo de interés creciente tanto para la industria como para la investigación académica, pero se enfrenta a un reto que va más allá de la manipulación física: la información que debería guiar la decisión de *qué* prenda seleccionar rara vez está disponible, en tiempo útil, en el punto donde se ejecuta la acción robótica.

B. Dos brechas tecnológicas

Este trabajo identifica y aborda dos brechas concretas que coexisten en los centros de distribución modernos de moda:

- **La brecha IT ↔ OT.** Los departamentos de marketing analizan de forma continua las tendencias en redes sociales y generan inteligencia de mercado sobre qué estilos están en auge y en qué mercados. Esa inteligencia, sin embargo, no fluye de forma automática hacia las operaciones de almacén: el sistema que ejecuta el picking no tiene ningún mecanismo hoy para saber que, por

ejemplo, en el Reino Unido está emergiendo una estética de minimalismo urbano en tonos pastel.

- **La brecha de resolución tipo-SKU en visión.** Los sistemas de clasificación de prendas del estado del arte identifican categorías generales (camiseta, pantalón, vestido), pero una decisión de picking orientada a tendencias exige conocer la referencia exacta de catálogo (SKU) y sus atributos — corte, material, estética, mercado de destino. Identificar un SKU concreto a partir de una prenda doblada dentro de una caja exige un nivel de reconocimiento visual superior al de la clasificación por categoría genérica que domina la literatura.

C. Por qué robótica colaborativa

La elección de robots colaborativos (*cobots*) frente a robots industriales de trayectoria fija responde a tres consideraciones de diseño. En primer lugar, las prendas son objetos blandos y no rígidos cuya posición dentro de una caja varía de forma sustancial de un contenedor a otro; los cobots, combinados con percepción visual y control de fuerza, se adaptan mejor a esta variabilidad que un manipulador industrial clásico programado por trayectoria. En segundo lugar, los almacenes de moda son, hoy y en el futuro previsible, entornos mixtos hombre-máquina; los cobots permiten que operarios y robots compartan espacio de trabajo sin necesidad de celdas de seguridad físicas costosas. Por último, la reconfigurabilidad de un cobot — pasar de clasificar camisetas a clasificar calzado, por ejemplo — implica una actualización de software, no una reingeniería mecánica, lo cual resulta especialmente valioso en un sector cuyo catálogo cambia de temporada en temporada.

D. Hipótesis y contribuciones

La hipótesis que articula este trabajo de investigación, y que dará forma al Trabajo Fin de Máster subsiguiente, puede resumirse así: *un sistema robótico bimanual puede cerrar el bucle IT-Middleware-OT de forma completa, desde el análisis de tendencias de moda en redes sociales hasta la selección física de prendas en el almacén, empleando modelos multimodales visión-lenguaje como puente semántico entre el lenguaje de la moda y la visión del robot.*

Las contribuciones esperadas de esta línea de investigación, y que se desarrollan a lo largo del artículo, son las siguientes:

- 1) Una revisión crítica del estado del arte que conecta tres campos — manipulación robótica de textiles, clasificación de prendas por visión y predicción de tendencias de moda — habitualmente tratados de forma aislada en la literatura.
- 2) Una propuesta de taxonomía de prendas orientada específicamente a la tarea de picking industrial, que separa de forma explícita lo que puede resolverse de forma fiable mediante percepción visual de lo que debe resolverse mediante un catálogo estructurado.
- 3) Una arquitectura de cinco modos de operación progresivos que permite validar de forma incremental, desde la manipulación geométrica más simple hasta la

optimización multiobjetivo más ambiciosa, la hipótesis central del trabajo.

- 4) Un mecanismo de emparejamiento semántico prenda-tendencia basado en un espacio de representación compartido entre imagen y lenguaje, que traduce descripciones textuales de tendencias en decisiones de picking.

E. Estructura del artículo

El resto del artículo se organiza como sigue. La Sección II presenta la revisión del estado del arte. La Sección III describe la arquitectura propuesta a alto nivel. La Sección IV presenta la taxonomía de prendas y el principio de separación de responsabilidades entre percepción, catálogo y lenguaje. Las Secciones V y VI detallan, respectivamente, el pipeline de percepción y correspondencia de catálogo y el pipeline de inteligencia de tendencias. La Sección VII aborda los modos de reposición geográfica y optimización multiobjetivo. La Sección VIII describe la capa de ejecución robótica. La Sección IX enumera las métricas de evaluación previstas. La Sección X presenta escenarios de aplicación ilustrativos. La Sección XI resume la planificación de trabajo. La Sección XII discute limitaciones y trabajo futuro, y la Sección XIII concluye el artículo.

II. ESTADO DEL ARTE

A. Manipulación robótica de textiles en intralogística

La automatización de almacenes en el sector textil es un campo en expansión, pero desigualmente maduro según el tipo de artículo manipulado. Operadores como Ocado o AutoStore han desarrollado sistemas de almacenamiento y recuperación automáticos (AS/RS) de gran éxito comercial, pero orientados a contenedores estándar rígidos, no a prendas sueltas o dobladas dentro de cajas de geometría variable. La manipulación de objetos deformables (*deformable object manipulation*) continúa siendo, en cambio, un problema abierto en robótica: a diferencia de una caja rígida, una prenda no tiene una forma canónica estable, se pliega de forma distinta cada vez que se deposita y presenta oclusiones parciales frecuentes sobre sí misma. Los robots industriales clásicos, programados por trayectoria fija, no están pensados para esta variabilidad geométrica, mientras que los cobots dotados de control de fuerza y percepción visual en bucle cerrado ofrecen un marco mucho más adecuado. La literatura reciente en manipulación y percepción de objetos deformables en entornos domésticos e industriales, así como los estudios de revisión sobre manipulación textil para sistemas robóticos, coinciden en señalar que la brecha entre lo demostrado en laboratorio y lo desplegado en un centro de distribución real sigue siendo amplia, en particular cuando se exige, además de la manipulación, una identificación precisa del artículo manipulado [1], [2].

B. Clasificación de prendas mediante visión por computador

El campo de la clasificación y recuperación de prendas mediante visión artificial cuenta con hitos de referencia bien establecidos. DeepFashion [3] introdujo un conjunto de 800.000 imágenes con 50 categorías y más de mil atributos,

estableciendo el primer gran banco de pruebas para tareas de clasificación y recuperación de moda. DeepFashion2 [4] amplió este trabajo con casi medio millón de pares de imágenes orientados a la correspondencia entre fotografía de consumidor y fotografía comercial. iMaterialist [5] aportó 228 categorías con anotación de segmentación de grano fino, mientras que Fashionpedia [6] propuso una ontología completa de 27 categorías de prenda, 19 partes del cuerpo y 294 atributos, convirtiéndose en la anotación más exhaustiva disponible hasta la fecha. Estos conjuntos de datos comparten, no obstante, un rasgo común: han sido contruidos a partir de fotografías de catálogo o de consumidor, con prendas puestas sobre un maniquí, un modelo o el propio usuario, en condiciones de iluminación favorables. Ninguno de ellos contempla el escenario industrial que interesa a este trabajo — una prenda doblada dentro de una caja de cartón, observada desde una cámara cenital bajo iluminación de nave industrial —, lo que constituye una brecha de dominio (*domain gap*) relevante para cualquier sistema de picking real.

C. Modelos multimodales visión-lenguaje

La aparición de modelos de representación conjunta imagen-texto ha transformado el panorama de la clasificación visual de propósito general. CLIP [8], entrenado sobre 400 millones de pares imagen-texto recogidos de Internet, demostró que es posible construir un espacio de representación compartido donde imágenes y descripciones textuales semánticamente afines quedan próximas entre sí, habilitando tareas de clasificación y recuperación sin necesidad de reentrenamiento específico (*zero-shot*). ALIGN [9], desarrollado de forma paralela por Google sobre 1.800 millones de pares, confirmó la robustez de este paradigma a mayor escala. Más recientemente, FashionCLIP [10] adaptó específicamente este enfoque al dominio de la moda y el comercio electrónico, mejorando la precisión sobre catálogos reales de producto. En el terreno de la detección con lenguaje natural, Grounding DINO [11] ha abierto la posibilidad de localizar objetos en una escena a partir de una descripción textual arbitraria, sin necesidad de un conjunto cerrado de clases previamente entrenadas, lo que lo convierte en una alternativa de interés cuando los datos de entrenamiento disponibles son escasos. El denominador común de esta familia de modelos es que, por primera vez, ofrecen un vocabulario visual y textual compartido: precisamente el ingrediente que permite, como se discute en la Sección VI, comparar de forma directa una descripción de tendencia redactada en lenguaje natural con la fotografía de una prenda física.

D. Predicción de tendencias de moda mediante inteligencia artificial

La predicción de tendencias de moda (*fashion trend forecasting*) es un área de interés creciente tanto comercial como académico. Servicios como WGSN llevan más de dos décadas ofreciendo predicción de tendencias basada en el análisis combinado de redes sociales, patrones de búsqueda, datos de venta e informes de pasarela, y constituyen la referencia de facto del sector. En el ámbito puramente académico,

Fashion-MNIST [7] se ha consolidado como banco de pruebas clásico para clasificación de imágenes de prendas, si bien su simplicidad — diez clases en escala de grises — lo hace inadecuado para tareas de matiz estético. Un cuerpo de investigación más reciente, procedente de laboratorios como el NYU Fashion Lab o el MIT Media Lab, ha explorado el análisis de *hashtags* en Instagram y Pinterest para detectar tendencias emergentes mediante procesamiento de lenguaje natural. La novedad más reciente, y todavía sin consolidación en publicaciones académicas formales, es el uso de grandes modelos de lenguaje con acceso a búsqueda web como generadores de resúmenes de tendencia bajo demanda: un modelo de lenguaje puede sintetizar, a partir de contenido viral reciente, una descripción textual de qué estética domina un mercado en un momento dado. Esta capacidad, emergida en 2023-2024, es un ingrediente central de la arquitectura propuesta en la Sección VI, y su combinación con los modelos visión-lenguaje de la Sección II-C es, hasta donde alcanza esta revisión, un vacío de investigación abierto.

E. Integración IT/OT e Industria 4.0

La integración entre los sistemas de información de negocio (IT) y los sistemas de operación de planta (OT) es uno de los ejes centrales del paradigma de Industria 4.0 y de los sistemas ciber-físicos (*Cyber-Physical Systems*, CPS), que describen precisamente el tipo de lazo de realimentación entre inteligencia de negocio y ejecución física que este trabajo pretende cerrar. En el terreno de la automatización industrial, OPC-UA se ha consolidado como estándar de comunicación IT/OT de referencia. En robótica, ROS 2 — descrito en detalle por Macenski *et al.* [12] — ha ganado tracción como capa de middleware capaz de integrar componentes IT (interfaces web, modelos de aprendizaje automático, APIs) con componentes OT (autómatas programables, controladores de robot), y cuenta con soporte oficial en plataformas colaborativas industriales como el ABB GoFa. El protocolo de control externo de movimiento de ABB (*Externally Guided Motion*, EGM) complementa esta capa, permitiendo el envío de consignas de posición en tiempo real desde un nodo de procesamiento externo hacia el controlador del robot.

F. Síntesis y posicionamiento

La revisión anterior permite identificar con precisión el vacío que este trabajo pretende cubrir. Existe una literatura madura sobre manipulación robótica de objetos deformables, pero centrada en la manipulación física, no en la decisión de *qué* manipular. Existe una literatura extensa sobre clasificación visual de prendas, pero orientada a fotografía de catálogo, no a la condición industrial de una prenda doblada en caja. Existe una literatura emergente sobre modelos visión-lenguaje capaces de tender un puente semántico entre imagen y texto, pero sin aplicación documentada a la decisión de picking físico. Y existe, por último, una práctica comercial de predicción de tendencias de moda que opera completamente desacoplada de las operaciones de almacén. Ningún trabajo revisado integra estos cuatro elementos — manipulación, clasificación fina,




Fig. 1. Arquitectura propuesta en tres capas (IT-Middleware-OT).

representación visión-lenguaje y tendencias de mercado — en un único sistema robótico de extremo a extremo. Esta es, precisamente, la propuesta que se desarrolla en el resto del artículo.

III. ARQUITECTURA PROPUESTA DEL SISTEMA

A. Visión general en tres capas

La arquitectura propuesta se organiza en tres capas claramente diferenciadas — IT, Middleware y OT — que reproducen, de forma deliberada, la separación conceptual habitual en los sistemas ciber-físicos de Industria 4.0. La Figura 1 resume esta organización. La capa IT concentra la inteligencia de negocio: el catálogo clasificado por marketing y el análisis de tendencias en redes sociales mediante modelos de lenguaje, sometido a aprobación por parte de un operario antes de tener ningún efecto sobre la planta. La capa de Middleware, construida sobre ROS 2, aloja el catálogo estructurado de producto y el pipeline de percepción que traduce imagen en identidad de producto. La capa OT ejecuta físicamente el picking mediante dos brazos robóticos colaborativos y su sensorial asociado.

B. Modos de operación progresivos

Con el fin de validar la hipótesis central de forma incremental, la arquitectura se organiza en cinco modos de operación, cada uno de los cuales añade una capa de inteligencia sobre el anterior sin invalidarlo. La Tabla I resume esta progresión.

Cada modo es, a la vez, un objetivo experimental independiente y un escalón necesario para el siguiente: el Modo 2 no puede evaluarse sin que el Modo 1 aporte una imagen limpia de la prenda; los Modos 3 y 4 comparten como prerrequisito la identificación de SKU que aporta el Modo 2; y el Modo 5 no es más que la composición formal de los Modos 3 y 4, descrita en la Sección VII.

TABLE I
MODOS DE OPERACIÓN PROPUESTOS

Modo	Nombre	Aportación
1	Vaciado geométrico	Singulación y depaletizado de cajas mediante detección orientada y nube de puntos
2	Clasificación supervisada	Identificación del tipo genérico de prenda y de la referencia exacta de catálogo
3	Reposición geográfica	Picking orientado a la demanda declarada por mercado de destino
4	Tendencias de mercado	Picking orientado a la afinidad con tendencias sociales vigentes
5	Gestión integral	Optimización conjunta de demanda geográfica y tendencia, cierre completo del bucle IT-OT

TABLE II
PLATAFORMA ROBÓTICA Y SENSORIAL PROPUESTA

Componente	Rol
Brazo colaborativo (×2)	Picking izquierdo / derecho y asistencia bimanual
Cámara cenital de profundidad	Detección de cajas y clasificación de prendas
Cámara en muñeca (×2)	Ajuste fino de agarre mediante servoing visual
Autómata de seguridad	Máquina de estados y supervisión de seguridad
Panel de operador	Selección de modo, aprobación de tendencias, estado
Estación de procesamiento	Inferencia de percepción y nodo de middleware

C. Plataforma robótica y sensorial

La plataforma física propuesta combina dos brazos colaborativos de seis grados de libertad — que permiten tanto el reparto de carga entre ambos brazos como la asistencia mutua en el agarre de prendas voluminosas — con una cámara cenital de profundidad para la percepción global de la caja y una cámara adicional solidaria a cada muñeca de robot para el ajuste fino de la posición de agarre mediante servoing visual. Un autómata programable gestiona la máquina de estados de seguridad de la célula de trabajo, y un panel de operador permite seleccionar el modo de operación activo, revisar tendencias pendientes de aprobación y supervisar el estado general del sistema. La Tabla II resume esta configuración.

IV. TAXONOMÍA DE PRENDAS ORIENTADA A PICKING ROBÓTICO

A. Criterios de diseño

Las taxonomías de moda del estado del arte descritas en la Sección II-B están diseñadas para tareas de anotación académica exhaustiva, no para la restricción particular de un sistema de percepción industrial en tiempo real. Este trabajo propone, en su lugar, una taxonomía diseñada bajo tres criterios simultáneos: distinguibilidad visual fiable incluso con la prenda parcialmente doblada; correspondencia directa con el vocabulario habitual de las tendencias de moda, de

TABLE III
COMPARACIÓN CON TAXONOMÍAS DE MODA DEL ESTADO DEL ARTE

Taxonomía	Año	Categorías	Enfoque
DeepFashion	2016	50	Clasificación y recuperación
iMaterialist	2019	228	Segmentación de grano fino
Fashionpedia	2020	27 + 294 attr.	Ontología completa
Propuesta	—	29 tipos	Picking industrial

modo que una tendencia detectada pueda vincularse a un conjunto concreto de tipos de prenda; y cobertura razonable del portafolio de una enseña de moda rápida multimarca.

B. Comparación con el estado del arte

La Tabla III compara la taxonomía propuesta con los conjuntos de datos de referencia introducidos en la Sección II-B. La diferencia esencial no es de tamaño, sino de reparto de responsabilidad: la propuesta reduce deliberadamente el número de clases que debe resolver la percepción visual de primer nivel, y traslada la resolución de atributos finos — corte, material, largo, ocasión — a un catálogo estructurado, según se detalla en la siguiente subsección.

La taxonomía propuesta organiza sus 29 tipos genéricos en seis familias — prendas de torso, prendas de la cintura hacia abajo, prendas de cuerpo entero, prendas de abrigo, calzado y accesorios — seleccionadas por presentar un rasgo estructural distinguible de forma fiable incluso con la prenda doblada dentro de una caja: la presencia o ausencia de mangas, de perneras separadas, de tacón o de compartimentos acolchados, entre otros. Rasgos que dependen en cambio del corte exacto de la prenda — por ejemplo, la diferencia entre un pantalón ajustado y uno holgado, o entre un vestido de fiesta y uno informal de playa — se excluyen deliberadamente de la taxonomía visual de primer nivel, porque su distinción fiable a partir de una imagen cenital de una prenda doblada no está garantizada, y porque dicha información puede obtenerse de forma inequívoca una vez identificada la referencia exacta de catálogo.

C. Separación de responsabilidades: percepción, catálogo y lenguaje

El principio de diseño central de esta propuesta, y su aportación más diferencial frente al estado del arte, es que ningún componente individual del sistema necesita, por sí solo, entender de moda. La responsabilidad se reparte en tres etapas encadenadas, ilustradas en la Figura 2.

En primer lugar, la percepción visual sobre la prenda física reduce el espacio de búsqueda indicando únicamente el tipo genérico — por ejemplo, “esto es un pantalón” — sin pronunciarse sobre material, corte o estética. En segundo lugar, la correspondencia de catálogo, apoyada en un espacio de representación compartido entre imagen y texto, identifica la referencia exacta de producto dentro del subconjunto acotado por la etapa anterior; esa referencia trae consigo, ya fijados en el catálogo por marketing, todos los atributos de estilo,

material y corte, que en ningún momento necesitan ser “detectados” de nuevo. En tercer lugar, y de forma completamente desacoplada de la percepción física — el agente de tendencias nunca observa una fotografía de la prenda ni del robot —, un modelo de lenguaje analiza contenido de redes sociales y devuelve una descripción textual de la tendencia vigente, empleando el mismo vocabulario de familias de estilo que ya emplea el catálogo. El emparejamiento semántico final, descrito en la Sección VI, cruza ambas fuentes de información en el mismo espacio de representación.

Esta separación aporta dos ventajas prácticas relevantes para un despliegue industrial real. Primero, un modelo de percepción con menos clases, cada una de ellas definida por un rasgo estructural claro, es más sencillo de entrenar y más robusto frente a variabilidad de pliegue o iluminación que un modelo que intentase además distinguir estilo o corte. Segundo, el catálogo estructurado se convierte en la única fuente de verdad para toda decisión de negocio: reclasificar una prenda de temporada no exige reentrenar ningún modelo de percepción, solo actualizar su ficha de catálogo.

V. PERCEPCIÓN Y CORRESPONDENCIA DE CATÁLOGO

A. Detección y singulación de cajas

La primera etapa del pipeline de percepción, correspondiente al Modo 1 de la Tabla I, resuelve un problema puramente geométrico: separar cajas individuales dentro de una escena en la que pueden llegar apiladas, giradas o parcialmente superpuestas, y estimar la posición y orientación de cada una para permitir su despaletizado ordenado. Esta etapa se apoya en segmentación de nube de puntos y detección de contorno orientado, y no requiere en ningún momento distinguir el contenido de la caja: su única responsabilidad es delimitar dónde se encuentra cada contenedor.

B. Clasificación por tipo genérico

Una vez abierta la caja, la segunda etapa observa la prenda en su condición real de almacén — doblada, bajo iluminación industrial, vista desde una cámara cenital — y determina a cuál de los 29 tipos genéricos de la taxonomía de la Sección IV pertenece. Es importante subrayar que esta condición de observación — prenda doblada, no puesta sobre un maniquí ni sobre una persona — es precisamente la que está ausente de los grandes conjuntos de datos de referencia descritos en la Sección II-B, lo que convierte la construcción de un conjunto de entrenamiento propio, específico de esta condición industrial, en una aportación necesaria de este trabajo.

C. Identificación de la referencia exacta de producto

La etapa de correspondencia de catálogo resuelve un problema distinto y más fino: dada una imagen y su tipo genérico, identificar cuál, de entre todas las referencias de ese tipo dadas de alta en el catálogo, es la prenda observada. Este trabajo propone abordar esta tarea como un problema de búsqueda por similitud en un espacio de representación compartido — el mismo principio que sustenta los modelos visión-lenguaje de la Sección II-C — en lugar de como un problema de




Fig. 2. Separación de responsabilidades entre percepción visual, correspondencia de catálogo, agente de tendencias y emparejamiento semántico.

clasificación cerrada. Cada referencia de catálogo se representa mediante el promedio de la representación visual de un pequeño número de fotografías propias, capturadas en la condición real de caja, y la identificación se resuelve buscando la referencia cuya representación es más cercana, en sentido de similitud coseno, a la de la imagen observada:

$$\text{SKU}^* = \arg \min_{i \in \text{catálogo}} d_{\cos}(v_{\text{robot}}, v_i) \quad (1)$$

donde v_{robot} es la representación de la imagen observada por el robot, v_i es la representación de la referencia i del catálogo dentro del subconjunto acotado por el tipo genérico detectado en la etapa anterior, y $d_{\cos}$ denota la distancia coseno entre ambos vectores.

Este planteamiento por búsqueda de similitud, frente a un clasificador dedicado entrenado con muy pocos ejemplos reales por referencia, presenta una ventaja operativa relevante para un catálogo de moda: dar de alta o de baja una referencia de producto es una operación de actualización de índice, no un reentrenamiento de modelo, lo que resulta imprescindible en un dominio donde el catálogo cambia de temporada en temporada.

VI. INTELIGENCIA DE TENDENCIAS Y EMPAREJAMIENTO SEMÁNTICO

A. Agente de tendencias

El agente de inteligencia de tendencias propuesto es un pipeline híbrido, no un único modelo, diseñado para operar de forma automatizada y desatendida a partir de fuentes reales de contenido social. La cadena combina, de forma conceptual, una etapa de recolección de contenido viral de moda, una etapa de transcripción de dicho contenido a texto, una etapa de clasificación mecánica que extrae etiquetas de estilo, y una etapa final de síntesis que redacta una descripción de tendencia en lenguaje natural y la clasifica dentro de un vocabulario cerrado de familias de estilo — el mismo vocabulario que ya

emplea el catálogo de producto, condición imprescindible para que ambos lados del sistema sean comparables. Esta cadena se ejecuta de forma periódica y completamente desatendida, sin intervención humana durante su ejecución, lo que la hace compatible con una operación de análisis de tendencias continua y de bajo coste operativo.

B. Flujo de aprobación humano en el bucle

Ninguna tendencia detectada por el agente automatizado tiene efecto directo sobre la operación de picking. Como ilustra la Figura 3, el resultado de cada análisis queda en un estado pendiente hasta que un operario, desde el panel de planta, revisa la descripción generada y decide si resulta coherente con el negocio. Solo tras esa aprobación explícita se actualiza el índice de tendencias activas que utiliza el picking. Este diseño responde a una consideración deliberada de gobernanza: la decisión de negocio de qué tendencia perseguir permanece siempre bajo supervisión humana, y el sistema automatizado actúa exclusivamente como generador de propuestas.

C. Emparejamiento semántico prenda-tendencia

Una vez aprobada, la descripción de tendencia y la fotografía de cada referencia de catálogo se proyectan en el mismo espacio de representación compartido introducido en la Sección II-C, lo que permite calcular una afinidad semántica continua entre ambas mediante similitud coseno:

$$s_{\text{sem}}(k, t) = \frac{v_k \cdot v_t}{\|v_k\| \|v_t\|} \in [-1, 1] \quad (2)$$

donde v_k es la representación visual de la referencia de catálogo k y v_t es la representación textual de la tendencia t . Esta señal semántica continua se complementa con una señal categórica que favorece, sin descartar el resto, a las referencias cuya familia de estilo coincide explícitamente con la detectada por el agente de tendencias:




Fig. 3. Flujo de aprobación humano-en-el-bucle para tendencias detectadas automáticamente.

$$s(k, t) = s_{\text{sem}}(k, t) + \beta \cdot \mathcal{K}[\text{estilo}(k) \in \text{estilo}(t)] \quad (3)$$

con β un peso experimental pequeño frente al rango habitual de la similitud semántica. Cuando existen varias tendencias activas de forma simultánea — distintos mercados o distintos segmentos —, el score final de una referencia de catálogo se obtiene agregando la contribución de cada tendencia relevante, ponderada por su intensidad estimada, de modo que las tendencias más fuertes dominan el resultado sin anular por completo la contribución de señales más débiles pero coherentes entre sí.

VII. REPOSICIÓN GEOGRÁFICA Y OPTIMIZACIÓN MULTI OBJETIVO

A. Modo 3: reposición geográfica

El Modo 3 introduce una segunda fuente de inteligencia, de naturaleza estructurada en lugar de social: la demanda declarada por mercado geográfico. Cada referencia de catálogo lleva asociado el conjunto de mercados en los que está autorizada su venta — una condición que puede reflejar normativa local, adecuación cultural o acuerdos comerciales de exclusividad — y el sistema, ante un pedido que especifica únicamente un mercado de destino y una cantidad, sin detalle de artículo, selecciona las referencias con stock disponible cuyo mercado de destino coincide con el solicitado.

B. Modo 5: optimización multiobjetivo

El Modo 5 combina los Modos 3 y 4 dentro de un único criterio de decisión: la demanda geográfica actúa como restricción dura sobre el conjunto de referencias elegibles, mientras que la afinidad con tendencias, calculada mediante la Ecuación (3), actúa como criterio de ordenación blando dentro de ese conjunto ya filtrado. De este modo, un mismo pedido para un mercado concreto no se resuelve simplemente por disponibilidad de inventario, sino priorizando, dentro de lo permitido para ese mercado, las referencias más alineadas

con la tendencia vigente. Este modo constituye la validación final, de extremo a extremo, de la hipótesis central del trabajo: el cierre completo del bucle entre inteligencia de negocio y ejecución física.

VIII. EJECUCIÓN ROBÓTICA

La capa de ejecución robótica se apoya en ROS 2 como middleware de comunicación entre los módulos de percepción, catálogo, planificación y control de robot, siguiendo el patrón de integración IT/OT descrito en la Sección II-E. El planificador de picking traduce cada referencia seleccionada en una coordenada tridimensional de agarre, que se transmite al controlador del robot mediante el protocolo de control externo de movimiento en tiempo real descrito en la Sección II-E, permitiendo un ajuste continuo de la trayectoria a partir de la realimentación de posición del robot. Para el agarre de precisión, cada brazo incorpora una cámara solidaria a su muñeca que permite corregir, en el último tramo del movimiento, la posición exacta de agarre a partir de la posición real de la prenda observada — una técnica conocida como *servoing visual* basado en imagen —, compensando así la incertidumbre residual que la percepción cenital no puede resolver por sí sola. Finalmente, la coordinación bimanual permite procesar dos prendas en paralelo cuando la configuración del pedido lo permite, asignando cada prenda a uno de los dos brazos en función de la proximidad física dentro del almacén, la evitación de colisiones entre ambos brazos y el reparto equilibrado de carga de trabajo entre ellos.

IX. MÉTRICAS DE EVALUACIÓN PREVISTAS

Dado que este trabajo se sitúa en su fase de revisión y propuesta, previa a la implementación, la Tabla IV recoge los objetivos de diseño previstos para cada componente del sistema, que constituirán el marco de evaluación del futuro Trabajo Fin de Máster. Se distingue, en particular, un conjunto de métricas de calidad de percepción y correspondencia, de métricas de calidad del emparejamiento con tendencias — de naturaleza más cualitativa, al no existir un patrón de referencia objetivo para lo que constituye una selección “correcta” frente a una tendencia — y de métricas de desempeño físico del picking.

X. CASOS DE USO ILUSTRATIVOS Y APORTACIÓN ESPERADA

Con el fin de trasladar la arquitectura propuesta a un plano concreto y de valorar su aportación diferencial frente a la operativa actual de un centro de distribución de moda, se describen a continuación tres escenarios ilustrativos. Se trata de ejemplos hipotéticos, contruidos para razonar sobre la aportación esperada del sistema propuesto, y no de resultados obtenidos sobre una implementación real.

A. Escenario 1: reposición por demanda regional

Considérese un centro de distribución europeo que recibe, de forma simultánea, un pedido de reposición de 200 unidades para el mercado del Reino Unido y otro de 150 unidades para

TABLE IV
OBJETIVOS DE DISEÑO PREVISTOS POR COMPONENTE DEL SISTEMA

Componente	Métrica	Descripción	Objetivo
Clasificación visual	mAP@0.5	Precisión media sobre los 29 tipos de la taxonomía	> 0.85
Correspondencia de catálogo	Recall@1	La referencia correcta es la primera candidata	> 0.60
Correspondencia de catálogo	Recall@5	La referencia correcta figura entre las cinco primeras	> 0.85
Emparejamiento de tendencias	Precisión@K	Proporción de candidatos alineados con la tendencia entre los K seleccionados	> 0.70
Emparejamiento de tendencias	NDCG@K	Calidad del orden de los K candidatos seleccionados	> 0.75
Picking robótico	Tasa de éxito de agarre	Proporción de intentos sin fallo mecánico	> 0.90
Picking robótico	Tiempo de ciclo	Tiempo entre detección y depósito de la prenda	< 8 s/prenda
Sistema (Modo 4)	Latencia extremo a extremo (picking)	Del pedido al inicio de movimiento del robot	< 2 s
Sistema (Modo 4)	Latencia extremo a extremo (tendencias)	De la ejecución del agente al vector de tendencia activo	< 60 s

el mercado francés, sin más especificación que el mercado de destino y la cantidad. En la operativa manual habitual, un operario debe conocer, o consultar, qué referencias del catálogo están autorizadas para cada mercado antes de iniciar la selección física, lo que introduce un tiempo de preparación y un riesgo de error humano crecientes con el tamaño del catálogo. Bajo el Modo 3 propuesto, el sistema filtra automáticamente el catálogo disponible por mercado de destino en el instante en que se recibe el pedido, y entrega al planificador de picking dos listas ya acotadas y priorizadas por disponibilidad de stock, reduciendo el tiempo de preparación de la orden de trabajo a una fracción del tiempo actual y eliminando por completo el riesgo de selección de una referencia no autorizada para su mercado.

B. Escenario 2: picking orientado a tendencias virales

Considérese ahora un escenario en el que el agente de tendencias detecta, a partir de contenido reciente en redes sociales, una estética de minimalismo urbano en tonos pastel ganando fuerza en el mercado británico, y el operario de planta aprueba dicha tendencia desde el panel de operador. Bajo la operativa actual, esta información — generada por el departamento de marketing o por un servicio externo de análisis de tendencias — rara vez alcanza a la planta de picking en un plazo útil, y cuando lo hace, su traducción a una selección concreta de referencias de catálogo depende del criterio manual de un responsable de producto. Bajo el Modo 4 propuesto, la tendencia aprobada se traduce automáticamente, en menos de un minuto, en un reordenamiento de las referencias candidatas dentro del segmento de producto afectado, de modo que las siguientes órdenes de picking para ese mercado priorizan, de forma automática, las prendas visualmente más afines a la estética detectada — sin que ningún operario de planta necesite tener conocimiento de moda para tomar esa decisión.

C. Escenario 3: gestión integral multiobjetivo

Combínense ambos escenarios anteriores bajo el Modo 5: un pedido de reposición para el mercado británico se resuelve seleccionando, dentro del conjunto de referencias autorizadas para ese mercado, aquellas más afines a la tendencia de minimalismo urbano vigente. Frente a una operativa actual en la que estas dos fuentes de información — demanda geográfica

y tendencia de mercado — se gestionan, cuando se gestionan, de forma manual y desacoplada, este escenario ilustra la aportación central del trabajo: un único sistema robótico capaz de razonar simultáneamente sobre restricciones de negocio estructuradas y sobre señales de mercado no estructuradas, sin intervención humana más allá de la aprobación inicial de la tendencia.

D. Aportación diferencial frente al estado del arte

Los tres escenarios anteriores permiten sintetizar la aportación esperada de este trabajo frente a la revisión de la Sección II. Frente a la literatura de manipulación robótica de textiles, centrada en el reto físico del agarre, este trabajo añade una capa de decisión de negocio que determina qué agarrar y en qué orden. Frente a la literatura de clasificación de prendas por visión, orientada a fotografía de catálogo, este trabajo aporta una taxonomía y un conjunto de datos propios adaptados a la condición industrial real de picking. Y frente a la práctica actual de predicción de tendencias de moda, desacoplada de la operación física, este trabajo propone un mecanismo concreto — el emparejamiento semántico de la Sección VI — para trasladar esa inteligencia hasta la decisión robótica, cerrando un bucle IT-OT que, hasta donde alcanza esta revisión, no se encuentra descrito en la literatura de forma integrada.

XI. PLAN DE TRABAJO

La Tabla V resume la planificación prevista para el desarrollo del Trabajo Fin de Máster que dará continuidad a este trabajo de investigación tutelado, organizada en fases que respetan las dependencias técnicas entre modos de operación descritas en la Sección III-B: la infraestructura de middleware y control es condición previa para el Modo 1, que a su vez condiciona el Modo 2 y, a través de él, la correspondencia de catálogo de la que dependen tanto el Modo 3 como el Modo 4; el Modo 5 se aborda en último lugar por ser la composición de los dos anteriores.

Entre los riesgos identificados para esta planificación destacan la posibilidad de que la correspondencia de catálogo no alcance de forma directa los objetivos de precisión fijados en la Tabla IV, para lo cual se contempla como mitigación un ajuste adicional del espacio de representación compartido; y la posibilidad de que el tiempo disponible no sea suficiente

TABLE V
PLAN DE TRABAJO PREVISTO

Fase	Periodo	Objetivos clave
Teórica	Verano previo al curso	Revisión del estado del arte, definición de arquitectura y de la taxonomía de prendas (este documento)
Infraestructura y Modo 1	Primer trimestre del curso	Puesta en marcha del middleware y del control de robot; detección y singulación de cajas
Modo 2 y catálogo	Segundo trimestre	Clasificación por tipo genérico; herramienta de alta de catálogo; correspondencia de referencia exacta
Modos 3 y 4	Tercer trimestre	Reposición geográfica; agente de tendencias; emparejamiento semántico prenda-tendencia
Modo 5 y validación	Cuarto trimestre	Optimización multiobjetivo; servoing visual; evaluación de extremo a extremo frente a los objetivos de la Tabla IV
Redacción final	Cierre del curso	Memoria final del Trabajo Fin de Máster y preparación de la defensa

para completar el Modo 5 en su forma más ambiciosa, en cuyo caso se priorizará la validación sólida de los Modos 1 a 4 frente a la extensión de la optimización conjunta.

XII. LIMITACIONES Y TRABAJO FUTURO

Esta propuesta presenta, de forma consciente, tres límites que se documentan aquí con honestidad, por tratarse de un trabajo de alcance de máster y no de un sistema de producción.

En primer lugar, el filtro categórico del emparejamiento semántico depende de que el agente de tendencias devuelva siempre un valor perteneciente al vocabulario cerrado de familias de estilo del catálogo; un modelo de lenguaje de menor capacidad podría, en ocasiones, devolver un valor fuera de ese vocabulario, degradando silenciosamente el emparejamiento a su componente puramente semántico. Se contempla como mitigación una validación explícita de la salida del modelo frente al vocabulario cerrado antes de aceptar cualquier tendencia.

En segundo lugar, el etiquetado de estilo de cada referencia de catálogo lo realiza una persona de forma manual, lo que introduce un riesgo real de deriva de criterio a medida que crece el número de referencias etiquetadas. Como trabajo futuro se plantea explorar un etiquetado asistido por modelos de lenguaje, en el que el sistema proponga automáticamente los atributos de estilo de una referencia nueva y una persona se limite a confirmarlos o corregirlos, quedando este planteamiento fuera del alcance del presente trabajo por no constituir su núcleo de aportación investigadora.

En tercer lugar, el equilibrio del catálogo entre familias de estilo es, por construcción, prácticamente estático, mientras que la tendencia detectada es dinámica; un catálogo desequilibrado hacia unas pocas familias de estilo dejará a las tendencias detectadas en familias infrarrepresentadas con pocos candidatos reales entre los que elegir. Se acepta esta limitación para el alcance de este trabajo, y se señala como línea de trabajo futuro una estrategia activa de reposición de catálogo por familia de estilo en un escenario de despliegue de producción real.

XIII. CONCLUSIONES

Este artículo ha revisado el estado del arte en tres campos — manipulación robótica de textiles, clasificación de prendas

mediante visión por computador y modelos multimodales visión-lenguaje, y predicción de tendencias de moda mediante inteligencia artificial — y ha identificado un vacío de integración entre ellos: ningún trabajo revisado cierra, de extremo a extremo, el bucle entre la inteligencia de tendencias generada en los departamentos de marketing y la ejecución física del picking en un almacén de moda. A partir de este vacío, se ha propuesto una arquitectura de sistema robótico bimanual organizada en tres capas y cinco modos de operación progresivos, sustentada en una taxonomía de prendas diseñada específicamente para la condición industrial de picking y en un espacio de representación semántica compartido entre imagen y lenguaje que permite traducir descripciones textuales de tendencia en decisiones de selección física de producto. Los escenarios ilustrativos presentados sugieren que esta integración puede reducir de forma significativa el tiempo de preparación de pedidos orientados a mercado y habilitar, por primera vez, un picking robótico sensible a la tendencia de moda vigente sin intervención manual más allá de la aprobación de negocio. La validación experimental de esta propuesta, siguiendo el plan de trabajo y los objetivos de diseño descritos en las Secciones XI y IX, constituye el objeto del Trabajo Fin de Máster que da continuidad a esta investigación.

REFERENCES

- [1] J. Sanchez *et al.*, “Robotic manipulation and sensing of deformable objects in domestic and industrial applications,” *International Journal of Robotics Research*, 2018.
- [2] K. Lui *et al.*, “A survey on textile manipulation for robotic systems,” *IEEE Transactions on Automation Science and Engineering*, 2023.
- [3] Z. Liu, P. Luo, S. Qiu, X. Wang, and X. Tang, “DeepFashion: Powering robust clothes recognition and retrieval with rich annotations,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 1096–1104.
- [4] Y. Ge, R. Zhang, L. Wu, X. Wang, X. Tang, and P. Luo, “DeepFashion2: A versatile benchmark for detection, pose estimation, segmentation and re-identification of clothing images,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2019, pp. 5337–5345.
- [5] S. Guo *et al.*, “The iMaterialist fashion attribute dataset,” in *Proc. IEEE/CVF Int. Conf. Computer Vision Workshops (ICCVW)*, 2019.
- [6] M. Jia, M. Shi, M. Sirotenko, Y. Cui, C. Cardie, B. Hariharan, H. Adam, and S. Belongie, “Fashionpedia: Ontology, segmentation, and an attribute localization dataset,” in *Proc. European Conf. Computer Vision (ECCV)*, 2020, pp. 316–332.
- [7] H. Xiao, K. Rasul, and R. Vollgraf, “Fashion-MNIST: A novel image dataset for benchmarking machine learning algorithms,” *arXiv preprint arXiv:1708.07747*, 2017.

- [8] A. Radford *et al.*, “Learning transferable visual models from natural language supervision,” in *Proc. Int. Conf. Machine Learning (ICML)*, 2021, pp. 8748–8763.
- [9] C. Jia *et al.*, “Scaling up visual and vision-language representation learning with noisy text supervision,” in *Proc. Int. Conf. Machine Learning (ICML)*, 2021, pp. 4904–4916.
- [10] P. J. Chia *et al.*, “Contrastive language and vision learning of general fashion concepts,” *Scientific Reports*, vol. 12, no. 1, p. 18958, 2022.
- [11] S. Liu *et al.*, “Grounding DINO: Marrying DINO with grounded pre-training for open-set object detection,” *arXiv preprint arXiv:2303.05499*, 2023.
- [12] S. Macenski, T. Foote, B. Gerkey, C. Lalancette, and W. Woodall, “Robot Operating System 2: Design, architecture, and uses in the wild,” *Science Robotics*, vol. 7, no. 66, 2022.